

Algoritmos Genéticos para Optimización Multimodal

Sandra Alitzel Vázquez Chávez
Universidad Nacional Autónoma de México
alitzelvzch@gmail.com

Abstract—En este trabajo se evalúa el desempeño de un Algoritmo Genético binario aplicado a problemas de optimización no convexa y multimodal en ausencia de derivadas. Se analizan funciones benchmark clásicas —Rastrigin (dimensión 2 y 5), Himmelblau, Bukin N.6 y Eggholder— bajo distintos escenarios evolutivos. Los resultados muestran que la geometría del paisaje y la dimensionalidad influyen de manera crítica en la dinámica evolutiva, robustez y velocidad de convergencia del algoritmo.

I. Introducción

El presente estudio aborda el problema de optimización de funciones altamente multimodales donde no se dispone de información de gradiente. Formalmente, se busca resolver:

$$\min_{x \in \Omega} f(x) \quad (1)$$

donde la función objetivo puede presentar múltiples mínimos locales y topología irregular.

Este tipo de problemas surge frecuentemente en ingeniería, diseño estructural y optimización basada en simulación, donde la derivada no está disponible o no es confiable. En tales escenarios, los métodos deterministas basados en gradiente pueden quedar atrapados en mínimos locales.

Para enfrentar este desafío, se emplea un Algoritmo Genético (GA), cuya dinámica poblacional permite exploración global sin depender de derivadas.

II. Metodología

Se implementó un GA binario con:

- Codificación binaria con precisión mínima de 0.001.
- Selección por ruleta.
- Cruza de un punto.
- Mutación tipo bit-flip.
- Elitismo configurable.

La codificación binaria discretiza el espacio continuo. La transformación de una cadena binaria a variable real se realiza mediante:

$$x = a + \frac{\text{int}(b)}{2^L - 1}(b - a) \quad (2)$$

donde L representa la longitud en bits y $[a, b]$ el dominio de búsqueda.

El GA opera como un sistema dinámico poblacional donde el equilibrio entre exploración y explotación depende de la presión selectiva, la mutación y el elitismo.

III. Diseño Experimental

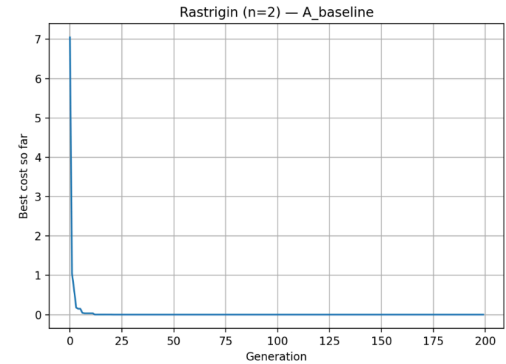
Se evaluaron cinco escenarios:

- A_baseline
- B_high_exploitation
- C_no_elitism
- D_high_mutation
- E_more_budget

Cada configuración fue ejecutada múltiples veces para evaluar desempeño mediano, tasa de éxito e intervalo intercuartílico (IQR).

IV. Resultados

A. Curvas de Convergencia



Population diagnostics


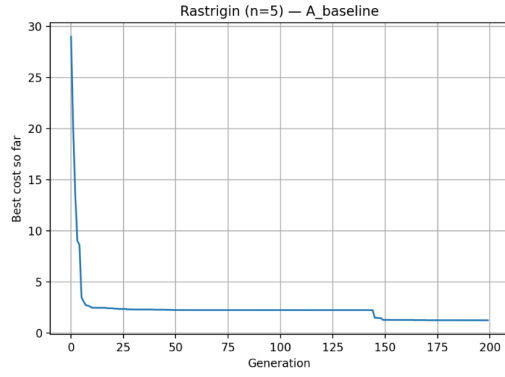


Fig. 1. Curva de convergencia para Rastrigin en dimensión 2 bajo escenario baseline.

La convergencia en dimensión 2 es rápida y estable, indicando baja dificultad del paisaje.



Population diagnostics


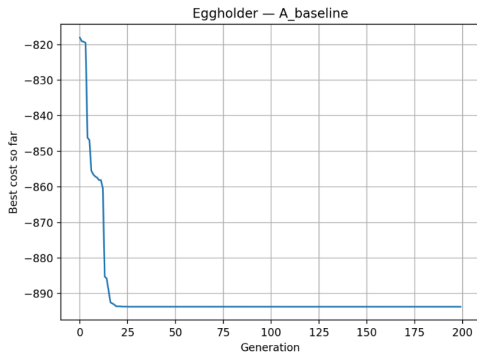


Fig. 2. Curva de convergencia para Rastrigin en dimensión 5.

En dimensión 5 se observa estancamiento prolongado, reflejando el incremento en complejidad combinatoria.



Population diagnostics




Fig. 3. Curva de convergencia para Eggholder.

Eggholder presenta mejoras escalonadas y alta variabilidad entre corridas.

B. Análisis Comparativo




Fig. 4. Eggholder

En términos de robustez, Eggholder bajo alta mutación mantiene exploración activa, pero no garantiza convergencia estable hacia el óptimo global.




Fig. 5. Rastrigin n=2

La alta mutación no afecta negativamente la estabilidad del proceso, ya que la estructura del paisaje en dimensión 2 facilita la localización del mínimo global incluso con mayor exploración. En este caso, el algoritmo demuestra alta robustez y baja sensibilidad a hiperparámetros.

TABLE I
Resumen comparativo de sensibilidad por función

Función	Dificultad	Presupuesto	Mutación	Elitismo
Rastrigin 2	Baja	No	Poco	No crítico
Himmelblau	Baja	Poco	Poco	Poco
Bukin	Media	Sí	Moderado	Sí
Rastrigin 5	Alta	Mucho	Sí	Sí
Eggholder	Muy alta	Sí	Muchísimo	Crítico

La tabla sintetiza la interacción entre geometría del paisaje y configuración evolutiva.

V. Discusión

La dificultad del problema depende de la dimensionalidad y rugosidad del paisaje. Rastrigin en dimensión 5 es más complejo que en dimensión 2 debido al crecimiento exponencial del espacio de búsqueda y al incremento en mínimos locales.

Incrementar la tasa de mutación favorece la exploración y preserva diversidad genética, pero incrementa la varianza entre corridas.

Eliminar el elitismo reduce estabilidad y aumenta dispersión de resultados, aunque puede evitar convergencia prematura.

El escenario de alta explotación converge más rápido, medido por menor tiempo mediano para alcanzar un umbral de calidad.

El escenario más robusto es aquel con menor IQR y mayor tasa de éxito, usualmente baseline o alta mutación dependiendo del problema.

VI. Conclusión

Los Algoritmos Genéticos constituyen una herramienta eficaz para optimización multimodal sin derivadas. Sin embargo, su desempeño depende críticamente de la interacción entre dinámica evolutiva y geometría del paisaje.

No existe una configuración universal óptima; la robustez emerge del equilibrio entre exploración y explotación en función del problema específico.